RL-дообучение GPT-2 для последовательных музыкальных рекомендаций

Смола Максим * **OpenAI Codex** **

* *Московский физико-технический институт, Москва, Российская Федерация*
** *ChatGPT University, San Francisco, California, USA*

Abstract: Исследовано RL-дообучение последовательной рекомендательной модели GPT-2 на подвыборке Yambda. Построены и сравнены модели отклика; для RL выбран CatBoost на замороженных эмбеддингах GPT-2 и пяти исторических признаках. Сравнены три функции награды, одношаговый и пятишаговый REINFORCE, разные ограничения KL и способы декодирования. RL увеличивает прогнозируемую долю прослушивания, однако изменения релевантности неоднозначны. Жадная пятишаговая генерация без ограничений почти всегда повторяет один объект. Запрет повторов устраняет вырождение, но сам по себе не подтверждает пользу RL. Обсуждаются ограничения reward model, повторного использования test и выводов о долгосрочных целях.

1. ВВЕДЕНИЕ

Кратко пайплайн нашего эксперемента: взяли первые 1000 историй, разделили события по времени на train / validation / test. Построили словарь по train, оставив треки с частотой ≥5.

Обучили GPT-2 предсказывать следующий трек: а вход - последние 64 трека, на выход - вероятности треков каталога. Сравнили top-K с общей популярностью и личными частотами пользователя.

Построили reward model: предсказывали долю прослушивания пары «история + кандидат». Сравнили Ridge, CatBoost, эмбеддинги GPT-2 и пять исторических признаков. Проверили разморозку GPT-2. Выбрали замороженную GPT-2 + пять признаков + CatBoost

Запустили одношаговый REINFORCE (упрощённая версия алгоса из статьи). GPT-2 случайно выбирает трек, CatBoost оценивает награду, обновляем GPT-2. Reward model заморожена, KL-штраф ограничивает отклонение от бейзлайна.

Сравнили три функции награды. Оценили рекомендации после RL. Провели некоторые дополнительные эксперименты: многошаговая генерация и обучение, контроль повторов и исследование компромисса между наградой и релевантностью через KL-штраф.

Мотивация заключается в том, что вероятность включить трек и полезность его прослушивания могут различаться (факт того, что трек будет включён следущим не гарантирует, что он будет полностью прослушан/поставлен лайк). Поэтому хотим исследовать: можно ли так повысить ожидаемую полезность, сохранив релевантность и разнообразие, или модель начнёт использовать ошибки оценщика, предпочитать популярные треки. Методология последней части эксперемента частична была взята из этой статьи

> **Дисклеймер**
>
> Далее следуют описание алгоритма и результаты эксперимента. Читателей, чувствительных к нейрослопу, просим отойти от экранов.

2. ПОСТАНОВКА ЗАДАЧИ

По истории взаимодействий пользователя требуется рекомендовать следующий трек. Идентификаторы треков выступают токенами GPT-2. На первом этапе модель обучается next-item prediction, затем отдельная reward model предсказывает долю прослушивания кандидата по истории. При RL обновляется только рекомендательная GPT-2; reward model остаётся фиксированной.

Исследуем не только рост предсказанной награды, но и изменение релевантности, популярности, знакомого контента и разнообразия. Отдельно рассматриваем генерацию пяти рекомендаций и влияние ограничения отклонения от бейзлайна. Предсказанная доля прослушивания является краткосрочным приближением полезности, а не непосредственной мерой удовлетворённости или возвращаемости.

3. ДАННЫЕ И ПРОТОКОЛ

Использованы первые 1000 пользовательских историй из listens.parquet Yambda; это подвыборка в порядке исходного файла, не случайная выборка пользователей. Разбиение проводится по общим временным границам: train_end = 20799987, val_end = 23399983. После исключения пользователей без train-истории остаётся 901 пользователь. В train 3 677 916 событий, в validation 584 811, в test 619 135. У 897 пользователей test-история непустая.

Словарь строится только по train: треки частоты не ниже пяти. Он содержит 86 239 треков, дополнительно PAD и UNK. Проверка исходных историй подтвердила порядок временных меток, непересечение временных периодов и точное соответствие сохранённого словаря train-частотам. Редкие и неизвестные треки контекста кодируются UNK.

3.1 Оценка релевантности

Один пример на пользователя: первый test-трек, контекст — train + validation. Оцениваются 897 пользователей с непустым test. GPT-2 использует последние 64 взаимодействия. Ранжируются все реальные треки словаря; PAD/UNK исключены, знакомые треки разрешены. Неизвестные цели не удаляются и считаются промахами; их доля около 30,7%.

Recall, NDCG и MAP считаются при K = 5, 10, 20 на одних примерах для всех моделей. Поскольку цель одна, Recall здесь равен HitRate, а AP — обратному рангу целевого трека при попадании. Не используем отрицательное сэмплирование при оценке: задача — найти один фактически следующий трек среди всего каталога. Другие потенциально подходящие треки считаются промахами.

3.2 Оценка отклика и защита от утечек

Для reward model равномерно выбираются 20 000 train-событий и по 5000 validation/test, seed 42. Включаем только события с известным целевым треком и непустой предыдущей историей. Это другой состав примеров, чем next-item test. Метрики отклика — MAE и RMSE в процентных пунктах; цель played_ratio_pct / 100, значения выше единицы не обрезаются.

Агрегаты откликов используют события строго раньше запроса, исключая события того же timestamp. Текущий отклик кандидата в признаки не входит; сам item_id кандидата входит намеренно. Длительность считается доступным атрибутом каталога. Test-оценка отклика является rolling: более ранние реальные события test могут быть историей для поздних, но веса не дообучаются на test.

Чекпоинты и параметры моделей выбирались по validation. Однако test просматривался многократно и влиял на планирование следующих экспериментов. Поэтому он не является полностью нетронутым финальным holdout. Прямого подмешивания test-откликов в обучение или текущих откликов в признаки при проверке не обнаружено; косвенное влияние test на исследование рассматриваем как ограничение, а не скрываем за выбором чекпоинтов по validation.

4. МОДЕЛИ И АЛГОРИТМ

4.1 GPT-2 бейзлайн

GPT-2 обучается со случайной инициализацией: 2 слоя, 4 головы, размерность 128, окно 64. Внутри пользователя используются окна с шагом 63; граница пользователей не склеивается. AdamW: lr = 0,0003, weight decay = 0,01, batch size 32, пять эпох, seed 42. Лучший checkpoint выбирается по validation cross-entropy.

Для сравнения используются общий top по частотам train и персональный частотный top по train + validation с дополнением общей популярностью. Они ранжируют тот же словарь, что и GPT-2. Персональные частоты видят всю историю, тогда как GPT-2 — только последние 64 трека.

4.2 Reward model

Замороженная GPT-2 кодирует последовательность «история + кандидат»; представление последней позиции имеет размерность 128. Проверены Ridge, CatBoost на этих эмбеддингах, CatBoost с пятью дополнительными признаками и CatBoost только на этих пяти признаках:

1. длительность кандидата;
2. средняя доля прослушивания трека по прошлым train-событиям;
3. средняя доля прослушивания пользователя по прошлой истории;
4. число прошлых прослушиваний кандидата пользователем;
5. доля прошлых событий пользователя с прослушиванием менее 50%.

При отсутствии прошлого пользовательское среднее равно 0,5, доля коротких прослушиваний — нулю; среднее трека заменяется средним по предшествующему train, а при полном отсутствии прошлого — 0,5.

Для Ridge alpha выбирается из 0,1; 1; 10; 100 по validation MAE; выбрано 0,1, решатель SVD. Для CatBoost: до 500 деревьев, глубина 6, lr = 0,05, loss RMSE, early stopping по validation MAE с ожиданием 50 итераций, seed 42, четыре CPU-потока.

Дополнительно проверялось совместное дообучение GPT-2 и линейной головы, инициализированной Ridge: три эпохи, MSE, lr backbone = 0,00001, lr головы = 0,0001, batch size 32. Обновлённые эмбеддинги также использовались для нового CatBoost с теми же пятью признаками. Заметного преимущества этого варианта над исходными эмбеддингами не получено; reward model для RL фиксируется на исходной GPT-2 и CatBoost с пятью признаками.

4.3 Награды и одношаговый REINFORCE

Пусть $\hat{r}(h, a)$ — прогноз доли прослушивания. Проверяем три награды:

- прогноз $\hat{r}(h, a)$;
- прогноз минус 0,1, если кандидат уже встречался в истории;
- прогноз за вычетом штрафа: 0,1 × train-частота кандидата / максимальная train-частота.

Популярность определяется только train. Штрафы не запрещают знакомые или популярные треки. Награды разных видов имеют разные определения; для общей шкалы отдельно сравниваем исходный прогноз доли прослушивания.

Для каждого контекста действие сэмплируется из распределения текущей GPT-2, без PAD/UNK. Оптимизируем

$$L = -E\left[(r-b)\log \pi_{\theta(a|h)}\right] + \beta D_{\mathrm{KL}(\pi_\theta,\pi_0)}. \qquad (1)$$

Здесь π_0 — отдельная замороженная копия исходной GPT-2; b — награда её жадного действия для того же контекста. Baseline не зависит от случайного действия политики. Dropout отключён, градиенты сохраняются только у обучаемой модели. KL считается точно по распределениям всех реальных треков, а CatBoost не дифференцируется.

Параметры: 5000 train-контекстов, 512 validation, две эпохи, batch size 32, lr = 0,00001, weight decay = 0,01, clipping градиента 1, seed 42. Первые сравнения наград используют beta = 0,05. Чекпоинт выбирается по средней validation reward минус beta × KL, включая исходную эпоху 0. Test в функцию обучения не передаётся.

4.4 Пять шагов и многошаговое обучение

Статический top-5 берёт пять треков из одного распределения по реальной истории. При авторегрессии первый выбранный трек добавляется в контекст, и распределение для следующей позиции вычисляется заново. При этом рекомендация не означает реальное прослушивание.

Сначала оцениваем одношаговые политики при жадной генерации пяти треков. Затем вводим контроль: маскируем только уже выбранные треки внутри списка, оставляя знакомые треки реальной истории разрешёнными. Изменение декодирования не меняет веса и не считается эффектом RL.

У reward model фиксируем реальные отклики, исторические агрегаты и время начала генерации. Сгенерированные ID добавляются только в контекст эмбеддингов и проверку повторов. Для тех же кандидатов дополнительно считается прогноз по исходному реальному контексту. Разница характеризует чувствительность прогноза к сгенерированному контексту, не его реальную ошибку.

При пятишаговом REINFORCE раннее действие обучается с учётом суммы наград до конца списка (return-to-go), gamma = 1. Будущие KL-штрафы также входят в возврат; прямой градиент точного KL вычисляется на каждом состоянии. Жадная траектория reference задаёт baseline. После маскирования обе политики нормируются на одинаковом множестве разрешённых треков. Графы пяти шагов пересчитываются последовательно, веса обновляются один раз после батча. Средние reward и KL нормируются на пять, отдельно сохраняется суммарная награда списка.

Для первого многошагового запуска используется штраф за повторы и запрет дублей, остальные параметры сохраняются. Число контекстов и optimizer-шагов то же, но сэмплируется в пять раз больше действий. Вычислительные бюджеты одношагового и многошагового обучения не равны.

4.5 Связь с предложенными статьями

В работе о GPTRec последовательная генерация и RL используются для целей за пределами точности, включая разнообразие и популярность. Заимствуем постановку анализа и сравнения компромиссов; PPO и teacher–student предобучение не воспроизводим. В работе об оптимизации сессий применяется off-policy REINFORCE с поправками по записанным взаимодействиям. Наши действия сэмплируются текущей политикой и оцениваются фиксированной reward model: это другая, модельная постановка, без off-policy corrections.

5. РЕЗУЛЬТАТЫ И АНАЛИЗ

5.1 Бейзлайн и простые стратегии

Table 1. Ранжирование первого test-трека по единому каталогу.

Стратегия	Recall@20	NDCG@20	MAP@20
Популярность	0,0156	0,0048	0,0020
Личные частоты	0,0936	0,0493	0,0370
GPT-2	0,0948	0,0484	0,0352

GPT-2 значительно превосходит общую популярность, но близка к личным частотам: 85 попаданий против 84 при K = 20. У личных частот выше NDCG и MAP. Это рабочая отправная точка, а не доказательство превосходства трансформера.

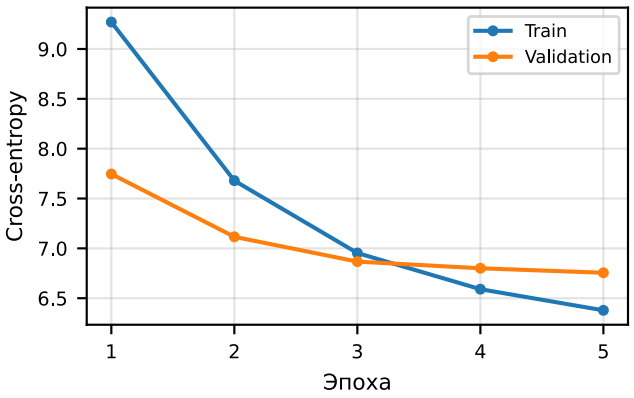


Fig. 1. История обучения сохранённого baseline.

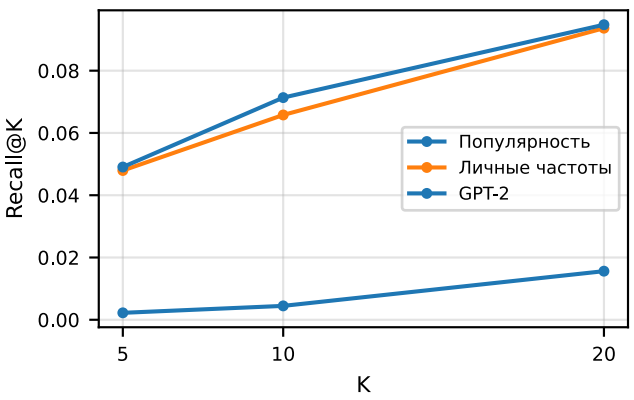


Fig. 2. Recall при разных K для GPT-2 и простых стратегий.

5.2 Качество предсказания отклика

Table 2. Ошибки reward models в процентных пунктах; CB — CatBoost.

Модель	Val MAE	Test MAE	Test RMSE
Среднее	42,3388	42,2497	44,4259
Среднее трека	39,1407	39,0110	43,7621
GPT + Ridge	38,9362	38,6076	42,5819
GPT + CB	37,8394	37,7106	41,6526
GPT + 5 + CB	32,9898	33,0898	39,1145
5 + CB	33,1247	33,2312	39,3852

Основной прирост дают пять признаков: MAE снижается с 37,71 до 33,09 п.п. Без эмбеддингов получено 33,23 п.п.; их добавочный вклад около 0,14 п.п. Сравнение не означает, что пять признаков лучше предсказывают следующий трек: здесь другая целевая переменная и более прямой сигнал прошлых дослушиваний.

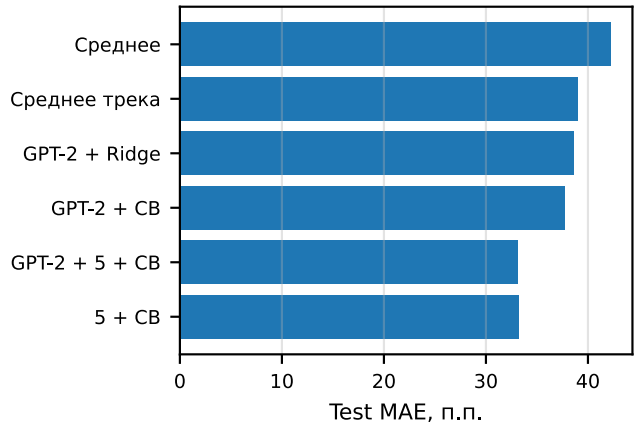


Fig. 3. MAE вариантов reward model на отложенных откликах.

Повторная оценка сохранённых весов подтвердила результат линейной разморозки: validation MAE 38,4185 п.п., test MAE 38,4686 против 38,6076 у Ridge, test RMSE 42,5752 против 42,5819 п.п. Улучшение небольшое и значительно уступает пользе исторических признаков. Оценка выполнена по сохранённому лучшему checkpoint.

CatBoost с дообученными эмбеддингами дал MAE 33,0775 против 33,0898 у исходных, но RMSE ухудшилась с 39,1145 до 39,1281 п.п.; обе validation-метрики также ухудшились. Прирост пренебрежимо мал на одном запуске. Ошибки reward model около 33 п.п. остаются большими, а MAE по наблюдаемым прослушиваниям не гарантирует верного ранжирования альтернативных кандидатов.

5.3 Три функции награды

Table 3. Одношаговый RL с beta = 0,05. Ratio — прогноз top-1; Recall и покрытие при K = 20.

Награда	Ratio, %	Recall	Покрытие, %
Бейзлайн	65,59	0,0948	11,65
Доля	66,16	0,0948	11,38
Популярность	65,94	0,0959	11,92
Повторы	66,07	0,0948	11,49

Без штрафа получен наибольший прогноз прослушивания, но выросли популярность и сходство списков. Штраф за популярность снизил среднюю популярность top-20 с 0,0972 до 0,0845 и overlap с 0,493% до 0,403%, увеличив покрытие. При штрафе за повторы доля знакомых треков top-20 снизилась с 68,32% до 67,22%. Однако доля знакомых треков в top-1 осталась 85,84%; прирост награды top-1 связан с прогнозом дослушивания, а не уменьшением повторов.

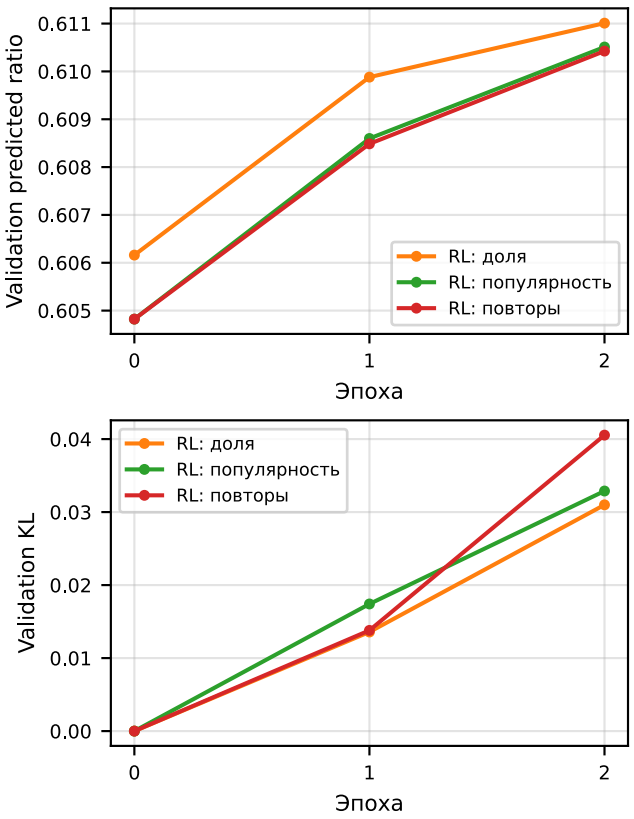


Fig. 4. Прогноз доли прослушивания и KL на validation.

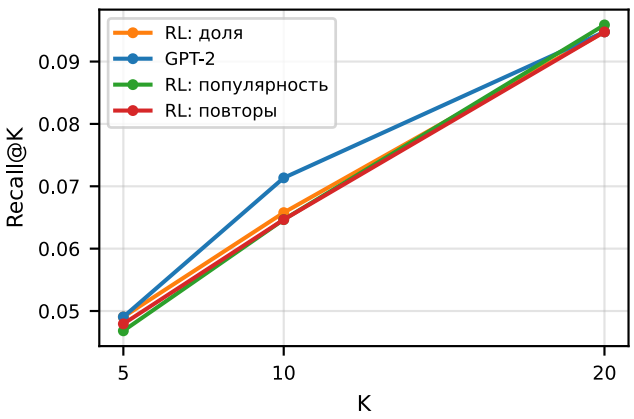


Fig. 5. Релевантность при разных функциях награды.

5.4 Генерация нескольких шагов

Table 4. Доля одинаковых пяти треков и попадания первого test-трека: с повторами и без дублей; 897 примеров.

Модель	**Одинаковы, %**	**Попадания**	**Без дублей**
Бейзлайн	98,22	18	40
Доля	97,55	19	40
Популярность	97,88	19	37
Повторы	97,10	22	38

При неограниченной жадной авторегрессии практически весь список состоит из одного трека. Это уже свойство бейзлайна, не только RL. Повторяется объект внутри списка одного пользователя; это не означает, что один объект рекомендуют всем пользователям.

Прогноз reward model с добавлением сгенерированных треков немного растёт, но попадания после первого шага не прибавляются. На пятом шаге средняя абсолютная разница с контрольным прогнозом около 1,4 п.п. Рост внутренней оценки при таком вырождении нельзя считать улучшением.

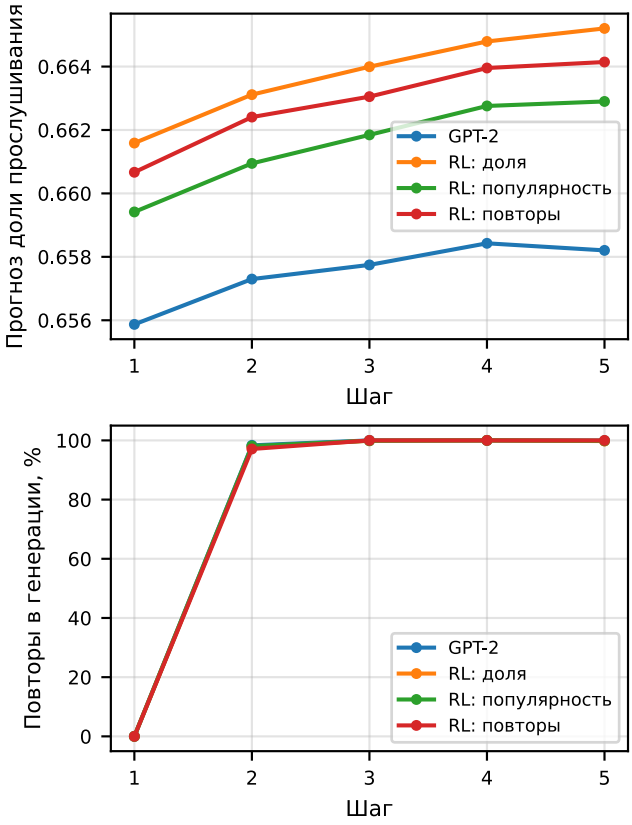


Fig. 6. Награда и повторы по шагам без ограничения декодирования.

Запрет повторов даёт пять уникальных треков по построению и увеличивает число попаданий. Однако RL listening лишь повторяет результат исходной модели, а штрафованные варианты дают меньше попаданий. Статический top-5 бейзлайна давал 44 попадания, авторегрессия без повторов — 40. При одинаковом декодировании преимущество RL по этому показателю не получено.

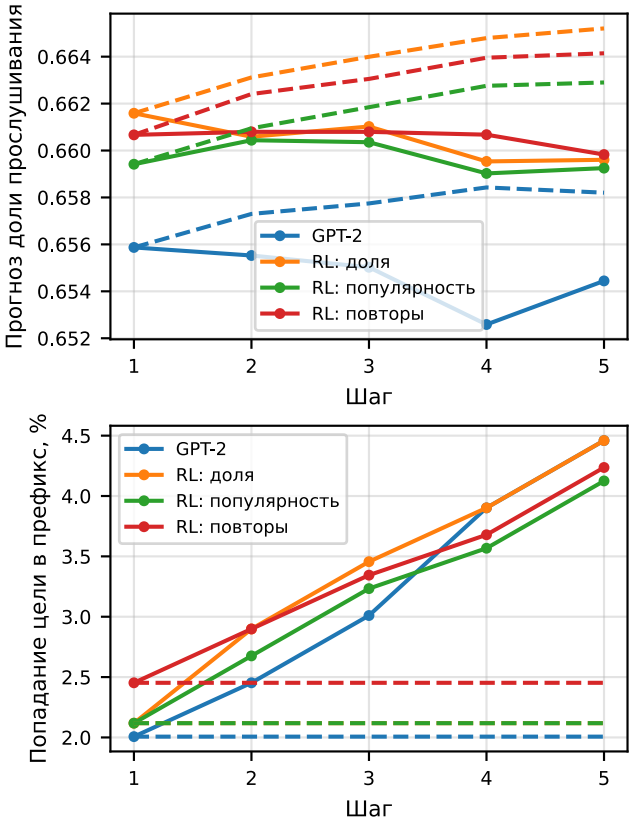


Fig. 7. Контроль декодирования: сплошные линии — без повторов, пунктир — исходная жадная генерация. Справа — попадание первого test-трека в префикс.

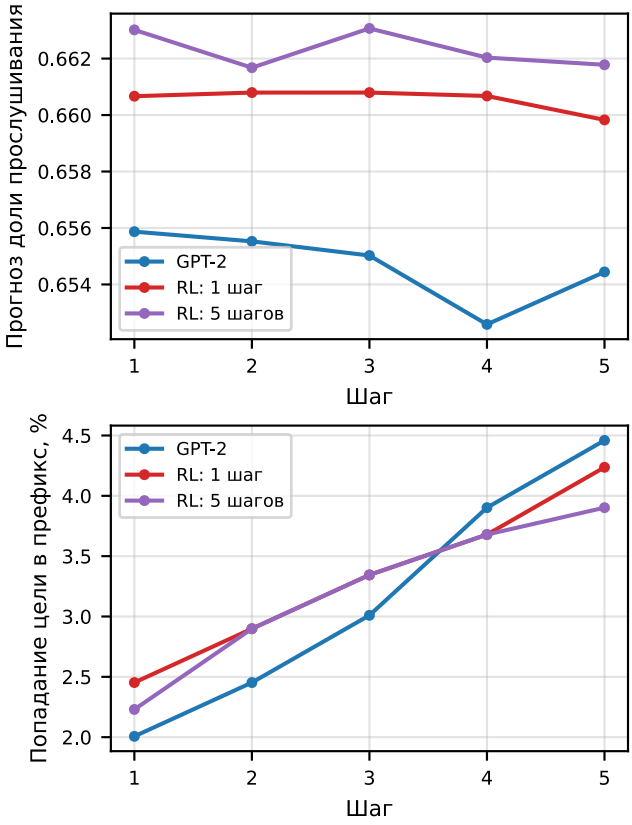


Fig. 8. Сравнение одношагового и пятишагового RL.

5.5 Пятишаговый REINFORCE

Table 5. Средние показатели пятишаговых списков при одинаковом запрете повторов.

Модель	Средняя ratio, %	Средняя награда	Попадания в 5
Бейзлайн	65,47	0,5774	40
RL 1 шаг	66,06	0,5838	38
RL 5 шагов	66,23	0,5857	35

Многошаговое обучение немного повышает прогнозируемую награду, но уменьшает число попаданий первого test-трека в сгенерированный список. В статическом top-5 новой модели 46 попаданий против 44 у бейзлайна; в top-20 — 84 против 85. Поэтому нельзя делать общий вывод об улучшении релевантности: статическое ранжирование и генерация дают разные результаты. Дополнительно различается бюджет по числу действий.

5.6 Сила KL-ограничения

Table 6. Одношаговый RL со штрафом за повторы; ratio top-1, Recall и NDCG при K = 20.

Коэф.	KL	Ratio, %	Recall	NDCG
Исходная	0,0000	65,59	0,0948	0,0484
0.01	0,0809	66,39	0,0903	0,0494
0.05	0,0400	66,07	0,0948	0,0495
0.2	0,0056	65,76	0,0992	0,0504

При слабом ограничении модель дальше отходит от reference и получает большую оценку CatBoost, но Recall@20 снижается до 81 попадания. При коэффициенте 0,05 остаётся 85, при 0,2 — 89. Все checkpoint выбраны по своей validation objective; для 0,2 — эпоха 1, для остальных — эпоха 2. Значения objective разных коэффициентов напрямую не сравниваются, поскольку содержат разные штрафы.

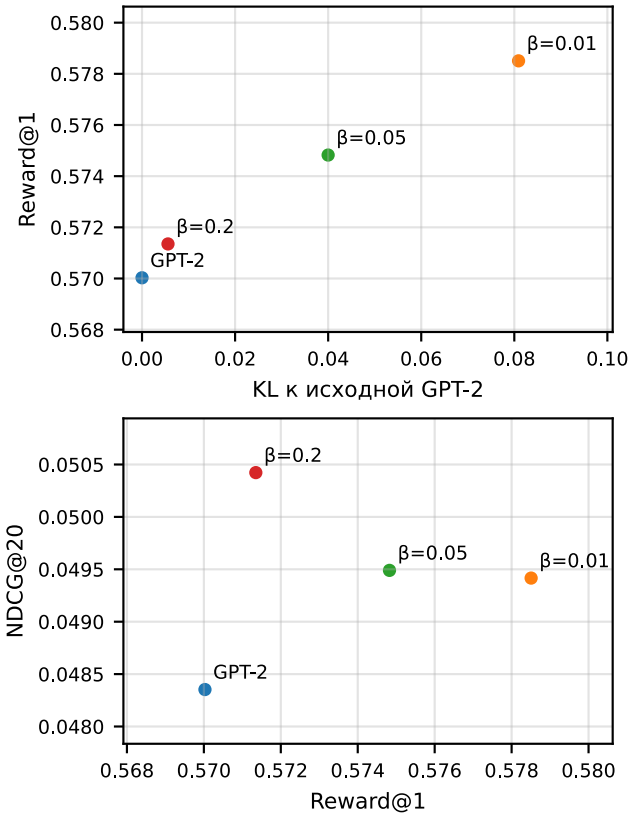


Fig. 9. Предсказанная награда, отклонение от reference и релевантность.

В этом запуске сильный штраф даёт более удачный результат по Recall/NDCG@20, но не по всем метрикам: Recall@10 остаётся ниже бейзлайна. При 0,01 выше MAP@20, несмотря на меньший Recall@20. Эти наблюдения не являются статистическим доказательством и не используются для объявления подобранного по test оптимального коэффициента.

6. ДОЛГОСРОЧНЫЕ ЦЕЛИ И ОГРАНИЧЕНИЯ

6.1 Что можно сформулировать по данным

Доля прослушивания характеризует отдельный трек. Более близкими к долгосрочным целям сигналами могли бы быть продолжение взаимодействий после рекомендации, время до следующего события и возвращение пользователя после перерыва. Порог разрыва сессии следует задавать по train, не подбирая его по test. Можно рассмотреть бонус за продолжение сессии или дисконтированную сумму прослушанного времени с дополнительным бонусом за возвращение.

Такие цели в выполненных экспериментах не обучались и не оценивались. Сумма пяти прогнозов доли прослушивания не измеряет удержание: алгоритм не моделирует уход пользователя, время не продвигается, отклики на сгенерированные треки неизвестны. Перемножение прогноза доли и длительности также потребовало бы отдельной проверки, не создаёт ли оно перекос к длинным трекам.

Офлайн можно проверить предсказуемость продолжения и возвращения по реальным временным меткам, отдельно оценить такую модель и поведение политики в явно описанном симуляторе. При этом необходимо учитывать правое цензурирование: отсутствие нового события у конца наблюдения не обязательно означает уход.

Утверждение, что конкретная рекомендация заставила пользователя вернуться, из наблюдаемой истории не следует. Есть влияние предпочтений, органических действий и прежней политики. Для причинного вывода потребуется онлайн-A/B проверка или дополнительные допущения и корректная off-policy оценка.

6.2 Ограничения выполненной работы

- Подвыборка небольшая и выбрана по порядку файла; один seed, без доверительных интервалов и проверки значимости различий в несколько попаданий.
- Высокая доля неизвестных целей ограничивает достижимую релевантность. Оценка reward model проводится только для известных треков и не эквивалентна оценке всех целей next-item.
- Reward model ошибается и обучалась на наблюдаемых прослушиваниях. При RL выбираются альтернативные объекты, для которых реальный отклик неизвестен.
- Оптимизация и измерение награды используют один CatBoost. Рост его score является внутренним результатом, а не независимым подтверждением полезности.
- Сгенерированные истории выходят за распределение реальных. Фиксация статистик откликов — осознанная аппроксимация, не симулятор пользователя.
- Один seed на разных устройствах не гарантирует одинаковые сэмплы: первые validation-оценки разных запусков немного различаются.
- Test многократно просматривался; для строгой финальной оценки нужна действительно неиспользованная когорта или временной период после фиксации протокола.
- У разных горизонтов разное число действий и вычислительные затраты. Влияние многошаговой цели нельзя полностью отделить от увеличения бюджета.

7. ВЫВОДЫ

В выводе тоже сам напишу пару слов.

Поставили работающий эксперимент, он объединяет GPT-2, оценённую reward model и RL-дообучение. Ответы на поставленные в задаче вопросы:

1. Модель начинает чаще выбирать треки, которым reward model даёт высокую оценки. Удалось увеличить заданное вознаграждение, но достижение максимума мы не доказали. Без штрафов средняя популярность top-20 растёт, а покрытие каталога уменьшается. Со штрафом за популярность получили обратное, причина - REINFORCE увеличивает вероятность действий

с высокой наградой. Поэтому изменение самой награды меняет привлекательность объектов: штраф за популярность делает популярные треки менее выгодными, ну а штраф за повторы - знакомые

2. В основном она остаётся близкой к бейзлайну, но не сохраняется одинаково на всех глубинах. Полного коллапса к общей выдаче не обнаружили

3. Можно изменить постановку так, чтобы учитывать продолжение взаимодействий и возвращение пользователя. Но наш выполненный эксперимент этого пока не проверяет. Касаемо офлайн и онлайн: офлайн можно проверить предсказуемость этих сигналов на позднем временном периоде. А вот для утверждения, что именно новая рекомендация вызвала возвращение нужно что-то вроде онлайн A/B-теста

4. При жадной генерации каждый выбранный трек добавлялся в контекст следующего шага. У 97–98% пользователей получались пять одинаковых треков. Проблема присутствовала уже у бейзлайна, а одношаговый RL почти не устранил её

5. Более сильная оптимизация оценки CatBoost может сопровождаться потерей релевантности или разнообразия. Например, слабый KL дал наибольший прогноз прослушивания, но меньше попаданий в top-20.

Главный же результат - повышение предсказанной награды без гарантии улучшения рекомендаций. Ограничение KL помогает сдерживать изменение политики, но при одном seed нельзя заключить, что найден универсально лучший вариант. Запрет повторов решает проблему декодирования, а не доказывает обучение полезной долгосрочной стратегии.